

Projekat: Analitika podataka i prediktivna analitika na podacima iz realnog problema

Faza 1: Pronalaženje podataka (1.5 nedelja: 29. Sept - 8. Okt) [3 poena]

Potrebno je izabrati inicijalni skup podataka iz stvarnog sveta iz domena kao što su zdravstvo, finansije, obrazovanje, itd.

Neki od sajtova na kojima možete pronaći podatke iz realnog sveta su:

<https://archive.ics.uci.edu/datasets>,

<https://www.kaggle.com/datasets>,

<https://data.gov/> ,

<https://data.worldbank.org/>

Nije obavezno da su podaci sa nekog od ovih sajtova, samo je potrebno navesti izvor gde su podaci nađeni.

Izlaz: Kratak opis skupa podataka, domen iz kog podaci dolaze. (Može da bude na početku Jupyter notebook-a)

Faza 2: Vizualizacija podataka i dinamičko predstavljanje (2 nedelje: 6 - 20. Okt) [4 poena]

Potrebno je kreirati vizualizacije za predstavljanje svojih podataka, koristeći alate kao što su *matplotlib*, *seaborn*. Ove vizualizacije treba da efikasno prenesu prirodu podataka i osnovnu, inicijalnu analizu.

Izlaz: Jupyter notebook sa kreiranim vizualizacijama ili sa dinamičkim vizualizacijama (opciono).

Prva presečna tačka – rezultat potrebno poslati do 20.10.2025. u 21h

Faza 3: Priprema podataka i istraživačka analiza (2 nedelje: 20. Okt - 3. Nov) [4 poena]

Potrebno je analizirati i prethodno obraditi odabrani skup podataka. Ovo uključuje bavljenje nedostajućim vrednostima, skaliranjem i, eventualno, tehnikama smanjenja dimenzionalnosti.

Tehnike: Deskriptivna statistika, korelacije, PCA (ako je potrebno).

Izlaz: Jupyter notebook sa opisanim koracima i zaključcima, kao i objašnjenja kako su rešeni problemi sa nedostajućim vrednostima, ako je rađeno smanjivanje dimenzionalnosti podataka, objašnjenje zašto i na koji način.

Faza 4: Statistička analiza i testiranje hipoteza (2 nedelje: 3 - 17. Nov) [4 poena]

Izvršiti testiranje hipoteza i statističko zaključivanje da bi doneli zaključke o skupu podataka.

Tehnike: Parametarski i neparametarski testovi, testovi normalnosti.

Izlaz: Jupyter notebook sa detaljima o rezultatima testiranja hipoteza i statističke analize.

Druga presečna tačka – rezultat potrebno poslati do 17.11.2025. u 21h

Faza 5: Prediktivno modeliranje i mašinsko učenje (2 nedelje: 17. Nov - 1. Dec) [7 poena]

Kreirati i uporediti nekoliko prediktivnih modela po izboru kao što su linearna regresija, logistička regresija ili SVM.

Izlaz: Jupyter notebook sa modelima koji uključuje trening, testiranje, evaluacione metrike (npr. tačnost, preciznost, odziv), kao i poređenje između modela i zaključke.

Faza 6: Napredno mašinsko učenje (2. nedelje: 1 - 15. Dec) [7 poena]

Implementirati naprednije modele po izboru, stabla odlučivanja i metode klasterovanja i neuronskih mreža.

Tehnike: K-means, stabla odlučivanja, perceptroni i backpropagation (propagacija unazad).

Izlaz: Jupyter notebook sa modelima koji uključuje trening, testiranje, i objašnjenje zašto su određeni modeli bili uspešniji od drugih.

Faza 7: Vremenske serije (1.5 nedelja: 15 - 24. Dec) [4 poena]

Implementirati modele vremenskih serija koristeći tradicionalne modele i neuronske mreže.

Tehnike: SARIMAX modeli, LSTM (Long Short-Term Memory) neuronske mreže, diferenciranje i priprema podataka tehnikom kliznog prozora. **Izlaz:** Jupyter notebook sa modelima koji uključuje trening, testiranje, i objašnjenje zašto su određeni modeli bili uspešniji od drugih.

Izlaz: Jupyter notebook sa modelima koji uključuje trening, testiranje, i objašnjenje zašto su određeni modeli bili uspešniji od drugih.

Treća presečna tačka – rezultat potrebno poslati do 24.12.2025. U 20h

Moguće je projekat poslati u celosti (oni koji nisu slali nijedan deo ranije) do **24.12.2025.** ali onda nije moguće ostvariti maksimalan broj bodova, već se taj slučaj sankcioniše sa -10 poena

Faza 8: Završna prezentacija i jupyter notebook (24. - 27. Dec) [2 poena]

Potrebno je pripremiti završnu prezentaciju koja sumira sve faze projekta.

Izlaz: Prezentacija (min 10, max 20 slajdova)

Prezentaciju je potrebno poslati do 27.12.2025. u 20h

Ukoliko se kasni sa slanjem od 1-3 dana za bilo koju kontrolnu tačku, to se sankcioniše sa -2 poena, svako veće kašnjenje podrazumeva da konkretna kontrolna tačka nije ispoštovana i biće sankcionisana sa -5 bodova.

Dodatna napomena: ukoliko se desi da na prvobitno izabranim podacima nije moguće uraditi neku od faza projekta, u tom slučaju može se iskoristiti dodatan set podataka (o tome je potrebno obavestiti asistenta).

Projekat se radi **samostalno**.

Projekat se brani u terminu vežbi **29.12.2025.** Potrebno je Jupyter notebook **nazvati svojim imenom i prezimenom** i poslati na mail imilutinovic@raf.rs